SEMESTRÁLNÍ PRÁCE

Využití Taylorova rozvoje (linearizace) pro odhad rozptylu výběrového kvantilu

4ST414 - Teorie výběrových šetření

Autor: František Pavlík

pavf05

Studijní program: Statistika

ZS 2025/2026

Úvod

Odhad populačního průměru a úhrnu je standardním úlohou výběrových šetření, pro kterou existují dobře definované a jednoduché vzorce pro rozptyl, jako je známé S^2/n v případě prostého náhodného výběru. Statistiky, které zajímají moderní analytiky a ekonomy, však často přesahují rámec prostých průměrů. Příkladem jsou kvantily, jako je medián nebo decily, které (na rozdíl od průměru) nabízejí robustnější pohled na rozdělení příjmů či majetku, jež bývají typicky sešikmená.

Zatímco bodový odhad výběrového kvantilu je přímočarý (stačí seřadit data a vybrat příslušnou hodnotu), nalezení jeho rozptylu, potažmo sestrojení intervalu spolehlivosti, je podstatně složitější problém. Výběrový kvantil není lineární funkcí pozorování, a proto nelze použít standardní vzorce pro rozptyl lineárních kombinací.

Definice problému

Teoretický rozptyl výběrového kvantilu závisí na hodnotě hustoty pravděpodobnosti populace v bodě daného kvantilu, $f(Q_p)$. Tato hodnota je však v praxi neznámá. Přímý odhad hustoty (např. pomocí jádrového vyhlazování) je numericky nestabilní a závisí na volbě "tuning parameters"(šířka vyhlazovacího okna), což vnáší do odhadu rozptylu dodatečnou nejistotu a subjektivitu.

Cíle práce

Cílem této práce je demonstrovat využití **Taylorovy linearizace (metody delta)** pro odhad rozptylu výběrového kvantilu, aniž by bylo nutné explicitně odhadovat hustotu $f(Q_p)$. Práce se zaměří na **Woodruffovu metodu** (Woodruff, 1952), která využívá inverzi intervalu spolehlivosti pro proporci.

Tato metoda bude podrobena simulační studii za účelem ověření její funkčnosti a robustnosti. Hlavní výzkumnou otázkou je:

- Jak ovlivňuje šikmost rozdělení (reprezentovaná log-normálním modelem) pokrytí (coverage probability) 95% intervalů spolehlivosti pro kvantily sestrojené pomocí Woodruffovy metody?
- Dostatečně "funguje"asymptotická teorie i pro malé a střední rozsahy výběru ($n = 200$ až 2000) u extrémnějších kvantilů (např. 90. percentil)?

1. Teoretická část

1.1 Výběrový kvantil a jeho asymptotické vlastnosti

Nechť $F(y)$ je distribuční funkce náhodné veličiny Y. Populační kvantil řádu p, kde $p \in (0, 1)$, značíme Q_p a definujeme jako:

$$Q_p = F^{-1}(p) = \inf\{y : F(y) \geq p\} \tag{1}$$

Výběrový kvantil $\hat{Q}_p$ z prostého náhodného výběru o rozsahu n je definován jako inverzní funkce k empirické distribuční funkci $\hat{F}_n(y)$.

Klíčovým poznatkem pro statistickou inferenci je asymptotická normalita výběrového kvantilu. Podle Bahadurovy reprezentace pro $n \to \infty$ platí:

$$\sqrt{n}(\hat{Q}_p - Q_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{[f(Q_p)]^2}\right) \tag{2}$$

Z tohoto vztahu vyplývá asymptotický rozptyl:

$$D(\hat{Q}_p) \approx \frac{p(1-p)}{n[f(Q_p)]^2} \tag{3}$$

Zde je jasně patrný problém závislosti na $1/f(Q_p)$. Pokud je hustota v bodě kvantilu malá (chvosty rozdělení), rozptyl je velký.

1.2 Taylorova linearizace

Linearizace je obecná technika pro aproximaci rozptylu nelineární statistiky $g(X)$. Rozvojem Taylorovy řady prvního řádu kolem střední hodnoty μ dostáváme $g(X) \approx g(\mu) + g'(\mu)(X - \mu)$. Aplikací operátoru rozptylu: $D(g(X)) \approx [g'(\mu)]^2 D(X)$.

V případě kvantilu narážíme na problém, že $\hat{Q}_p$ není jednoduchá funkce průměrů. Můžeme však linearizovat vztah mezi kvantilem a distribuční funkcí. Vyjdeme z rovnosti $\hat{F}(\hat{Q}_p) \approx p$. Taylorův rozvoj funkce $\hat{F}$ v bodě $\hat{Q}_p$ kolem Q_p dává:

$$\hat{F}(\hat{Q}_p) \approx \hat{F}(Q_p) + (\hat{Q}_p - Q_p) f(Q_p) \tag{4}$$

Odtud vyjádříme chybu odhadu:

$$(\hat{Q}_p - Q_p) \approx \frac{p - \hat{F}(Q_p)}{f(Q_p)} \tag{5}$$

Tento vztah převádí "vodorovnou"odchylku kvantilů na "svislou"odchylku distribuční funkce, škálovanou sklonem tečny (hustotou).

1.3 Woodruffova metoda

Woodruff (1952) navrhl elegantní metodu, která využívá výše uvedený princip linearizace, ale obchází nutnost znát $f(Q_p)$.

Postup sestává z následuících kroků:

1. Sestrojíme interval spolehlivosti pro očekávanou hodnotu distribuční funkce, tedy pro p. Pro hladinu významnosti α:

$$p_L = p - u_{1-\alpha/2}\sqrt{\frac{p(1-p)}{n}}, \quad p_U = p + u_{1-\alpha/2}\sqrt{\frac{p(1-p)}{n}} \tag{6}$$

2. Najdeme výběrové kvantily odpovídající těmto mezním pravděpodobnostem. Získáme tak interval $[\hat{Q}_{p_L}, \hat{Q}_{p_U}]$. Tento interval je $100(1-\alpha)\%$ intervalem spolehlivosti pro Q_p.
3. Pokud potřebujeme odhad směrodatné odchylky (Standard Error), odvodíme ji z délky intervalu (za předpokladu normality):

$$\hat{SE}(\hat{Q}_p) = \frac{\hat{Q}_{p_U} - \hat{Q}_{p_L}}{2u_{1-\alpha/2}} \tag{7}$$

Tato metoda implicitně "odhaduje"převrácenou hodnotu hustoty pomocí šířky intervalu mezi kvantily, což je mnohem stabilnější než odhad hustoty v jednom bodě.

2. Metodika a Data

2.1 Design simulační studie

Pro ověření vlastností Woodruffovy metody byla provedena Monte Carlo simulace v prostředí R. Cílem simulace je zjistit, jak přesně metoda odhaduje rozptyl a zda sestrojené intervaly spolehlivosti skutečně pokrývají populační parametr s deklarovanou pravděpodobností 95 %.

2.1.1 Populace a generování dat

Jako model pro generování dat bylo pro svou relevanci v ekonomických aplikacích (příjmová rozdělení) zvoleno **Log-normální rozdělení** $LN(\mu, \sigma)$. Byl fixován parametr polohy $\mu = 0$ (v logaritmické škále). Parametr tvaru σ nabýval hodnot $\{0.5, 1.0, 1.5\}$.

- $\sigma = 0.5$: Mírná šikmost, blízké normálnímu rozdělení.
- $\sigma = 1.5$: Extrémní šikmost a těžké chvosty.

2.1.2 Sledované parametry

Zajímáme se o odhad dvou kvantilů:

- **Medián** ($p = 0.5$): Robustní míra polohy.
- **90. percentil** ($p = 0.9$): Chvostový kvantil, kde je hustota pravděpodobnosti nízká.

Simulace byla provedena pro rozsahy výběru $n \in \{200, 500, 1000, 2000\}$. Počet replikací byl nastaven na $R = 1000$.

2.2 Metodika stanovení rozsahu výběru

Součástí analýzy je teoretický výpočet potřebného rozsahu výběru n pro dosažení požadované přesnosti Δ. Vycházíme z požadavku, aby poloviční šířka intervalu spolehlivosti nepřesáhla Δ. Z asymptotického rozptylu (3.3) plyne:

$$n \geq \frac{u_{1-\alpha/2}^2 p(1-p)}{\Delta^2 [f(Q_p)]^2} \tag{1}$$

Pro log-normální rozdělení je hustota dána vzorcem:

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}} \tag{2}$$

Tento vzorec ukazuje, že s rostoucím x (v chvostu u $\sigma = 1.5$) hustota $f(x)$ rychle klesá k nule. Protože $f(Q_p)$ je ve jmenovateli vzorce pro n, potřebný rozsah výběru roste s druhou mocninou převrácené hodnoty hustoty. To má dramatické důsledky pro plánování šetření zaměřených na extrémní kvantily.

3. Výsledky

Kapitola shrnuje výsledky simulační studie. Zaměřujeme se na dvě klíčové metriky:

1. **Relative Bias (Relativní zkreslení)**: O kolik procent Woodruffův odhad rozptylu nadhodnocuje nebo podhodnocuje skutečný rozptyl výběrového kvantilu (zjištěný empiricky z 1000 replikací).
2. **Coverage Probability (Pokrytí)**: Podíl intervalů spolehlivosti, které obsahovaly skutečnou hodnotu Q_p. Očekávaná hodnota je 0.95.

3.1 Analýza přesnosti Woodruffova odhadu

Tabulka 4.1 ukazuje výsledky pro $\sigma = 0.5$ (velmi mírná asymetrie). Vidíme, že metoda funguje excelentně. Pro $n = 500$ je pokrytí pro medián 0.946 a pro 90. percentil 0.959, což je blízko nominální hladině.

Tabulka 3.1: Výsledky simulace pro Log-Normal(0, 0.5) a Log-Normal(0, 1.5)

Sigma	**n**	**Kvantil**	**Bias (%)**	**Pokrytí**
0.5	200	Median	8.5 %	0.946
0.5	200	P90	32.6 %	0.953
0.5	2000	Median	10.0 %	0.955
0.5	2000	P90	14.0 %	0.952
1.5	200	Median	5.0 %	0.938
1.5	200	P90	**77.5 %**	0.959
1.5	2000	Median	3.5 %	0.946
1.5	2000	P90	6.3 %	0.946

Při zvýšení šikmosti na $\sigma = 1.5$ (spodní část tabulky) sledujeme zajímavý jev. U 90. percentilu pro $n = 200$ je relativní bias obrovský (77.5 %), což značí, že Woodruffova metoda silně nadhodnocuje rozptyl. Přesto je pokrytí (Coverage) konzervativní (0.959). To je způsobeno asymetrií skutečného výběrového rozdělení, kterou metoda nahrazuje symetrickým intervalem (nebo v našem případě je interval odvozen z robustních kvantilů, což ho činí širokým).

Se zvyšujícím se rozsahem výběru ($n = 2000$) bias klesá k přijatelným hodnotám (6.3 %) a pokrytí konverguje k 0.95.

3.2 Zhodnocení vlivu rozsahu výběru

Simulace potvrdila teoretický předpoklad, že pro odhady v "řídkých"oblastech hustoty (chvosty log-normálního rozdělení) konverguje rozptyl k asymptotickému tvaru pomaleji. Zatímco pro medián stačí i $n = 200$ k velmi spolehlivým výsledkům, pro 90. percentil silně sešikmeného rozdělení dává Woodruffova metoda při malých rozsazích výběru spíše konzervativní (příliš široké) intervaly, což vede k nadhodnocení rozptylu, ale "bezpečnému"pokrytí.

Závěr

Tato práce se zabývala aplikací Taylorovy linearizace ve formě Woodruffovy metody pro odhad rozptylu výběrových kvantilů. Hlavním přínosem práce je propojení teoretického aparátu (Bahadurův vztah, asymptotická normalita) s praktickou simulační studií na datech s log-normálním rozdělením.

Shrnutí zjištění

- **Robustnost metody:** Woodruffova metoda se ukázala jako překvapivě robustní. I v případech, kdy byl odhad rozptylu zkreslený (bias > 50 % u malých výběrů v chvostu rozdělení), intervaly spolehlivosti si zachovávaly požadované pokrytí cca 95 %. To z ní činí bezpečný nástroj pro praktické použití.
- **Vliv šikmosti:** Šikmost rozdělení má zásadní vliv na efektivitu odhadu. V oblastech s nízkou hustotou pravděpodobnosti (chvosty) roste rozptyl kvantilu dramaticky, což klade vysoké nároky na rozsah výběru.
- **Doporučení:** Pro praxi výběrových šetření lze Woodruffovu metodu doporučit jako standard. Při práci se silně sešikmenými daty (příjmy, aktiva) je však nutné počítat s tím, že pro přesný odhad extrémních kvantilů (např. 99. percentil) jsou nutné řádově tisícové rozsahy výběru, jinak budou intervaly spolehlivosti velmi široké.

Práce splnila své zadání demonstrovat nelineární metody odhadu ve statistice a potvrdila, že pro kvantilové charakteristiky nelze spoléhat na intuici vybudovanou na chování výběrových průměrů.

Abstrakt

Práce se zabývá problematikou odhadu rozptylu výběrových kvantilů, což je nelineární statistika, u které nelze použít standardní vzorce pro výběrový průměr. Představena je metoda Taylorovy linearizace ve formě Woodruffovy metody intervalové inverze, která umožňuje obejít nutnost přímého odhadu hustoty pravděpodobnosti. Teoretické poznatky jsou ověřeny v simulační studii na log-normálním rozdělení, která zkoumá vliv šikmosti rozdělení na pokrytí intervalů spolehlivosti. Výsledky ukazují, že zatímco pro medián je metoda robustní i při menších rozsazích výběru, pro krajní kvantily u sešikmených dat vyžaduje značně větší výběrové soubory k dosažení asymptotických vlastností.

Klíčová slova: Výběrový kvantil, Taylorova linearizace, Woodruffova metoda, Log-normální rozdělení, Simulace.

JEL Classification: C10, C42, C83.